

Trabajo Práctico 1: Establecimientos Educativos y Bibliotecas Populares

Fecha: 21/05/2025

Nombre del grupo: "B.O.B"

Integrantes:

- Tomas Libson
- Pedro Raffo
- Felipe Comas

RESUMEN:

En el grupo nos planteamos el objetivo de analizar, si existe, una relación entre la cantidad de Establecimientos Educativos y Bibliotecas Populares que hay por departamento. Para esto, lo primero que hicimos fue observar las tablas dadas, analizar su calidad de datos y limpiarlas en base a la información que íbamos a necesitar. De las tablas principales fuimos derivando tablas en formato 3FN para poder armar el DER y resolver los ejercicios. Una vez hecho esto, hicimos las consultas SQL a partir de las tablas limpias para cumplir con las indicaciones dadas en el enunciado. Todo esto agregando comentarios para que se entienda nuestro procedimiento. Luego, planteamos los gráficos pedidos en el mismo código. Por último, a partir de los datos obtenidos, llegamos a una conclusión del objetivo principal.

Introducción:

La Problemática con la cual se va a desarrollar este informe es si existe alguna relación entre la cantidad de Establecimientos Educativos y Bibliotecas Populares. Para poder responder a ésta, nuestro objetivo es manipular las bases de datos dadas (Tabla de Establecimientos Educativos, Tabla de Bibliotecas Populares y Tabla de Población) para así poder hacer un análisis de estos datos y entender la relación entre EEs y BPs. De manera que para desglosar los datos de estas bases vamos a llevar a cabo las siguientes actividades. Primero vamos a hacer un análisis de los datos de cada tabla. Es decir, determinar sus Formas Normales además de un análisis de Calidad de Datos para uno o más atributos que consideremos. Luego construiremos un DER para relacionar los atributos necesarios para responder a los ejercicios de SQL y gráficos. A partir de esto vamos a limpiar las Tablas Originales para obtener nuestro esquema relacional descrito en el DER. Ya con nuestro esquema, resolver las consultas SQL y realizar los gráficos. Finalmente realizaremos también observaciones e interpretaciones que respondan a la Problemática.

Procesamiento de datos :

TABLA EE:

El primer paso que tomamos para limpiar esta fuente de datos fue analizar la forma normal en la que se encontraba. Es fácil percatarse que esta tabla no está siquiera en 1FN. Por ejemplo, la columna "Teléfono" tiene valores multivaluados. Si bien muchas columnas contaban con valores no atómicos, múltiples filas vacías o erróneamente completadas (por ejemplo mails con una dirección no válida), la información que proporcionaban no era necesaria para cumplir con los objetivos pedidos.

Volviendo a la columna mails, es importante recalcar que se trata de un error de software. En esta columna podemos encontrar no solo filas vacías sino también mal completadas como por ejemplo: "MUSICANTEGUALEGUAYCHU YAHOO.COM.AR" (le falta el @) o "WWW.WILLIAMMORRISLR.COM.AR:" (ni siquiera es un mail). Esto afecta claramente a la

“Compleitud” de este casillero, ya que faltan valores para representar la realidad. Ante esta situación decidimos plantear la siguiente métrica para chequear la proporción de establecimientos educativos que tienen el campo correspondiente a mail vacío y/o con una dirección de mail no válida:

$$\frac{\text{Cantidad de registros con campo "Mail" vacío o no válido}}{\text{Cantidad total de registros}} = \frac{12023}{64711} \approx 0.19 \rightarrow 19\%$$

Para encontrar la cantidad de mails no válidos tomamos en cuenta los campos null y también todos aquellos que no contaran con un “@”. Entonces, aproximadamente hay un 19% de mails mal completados.

La mejora que proponemos ante este resultado es corregir el software de manera que la casilla sea obligatoria de completar y que se aporten instrucciones para que sea hecho de manera correcta (un único mail, válido)

Otro atributo de calidad que se ve afectado en la tabla original es el de “Corrección”. En el campo “Teléfono”, así como lo había en “Mail”, encontramos errores de todo tipo, como por ejemplo: “261 4” (incompleto) o “00 000” (no es un número de teléfono). Este tipo de respuestas están lejos de representar la situación real. La métrica que propusimos para encontrar la proporción de establecimientos educativos que tienen un teléfono inválido es la siguiente:

$$\frac{\text{Cantidad de registros con campo "Telefono" invalido}}{\text{Cantidad total de registros}} = \frac{57786}{64711} \approx 0.892 \rightarrow 89\%$$

La lógica que seguimos para encontrar la cantidad de teléfonos que no cumplían con los requisitos de un teléfono válido fue chequear aquellos que no tengan exactamente diez dígitos (sin contar guiones o espacios). Aproximadamente hay un 89 % de teléfonos inválidos.

Este número es inaceptable, y se debe también a un error de software. Por lo que sugerimos nuevamente: Hacer la casilla obligatoria y solicitar una respuesta de exactamente diez dígitos (sin contar guiones o espacios).

Tabla BP:

En cuanto a la Tabla de Bibliotecas Populares (BP), analizando su forma normal, encontramos que esta no cumple siquiera con la primera forma normal. Esto debido a que tiene múltiples columnas con valores no atómicos. Una de estas es la columna “Localidad”, que tiene casilleros como “Colonia Belgrano/ Wildermuth” nombrando dos localidades. Otro ejemplo puede ser la columna “Nombre” con apariciones como “Bib.Pop. Juan Vucetich, C.C. Y Dep. Aconcagua” donde se nombran dos asociaciones distintas. Por último, la columna “Domicilio” la cual, además de presentar valores no atómicos como “Av.M.Espinosa 26 / 40 0” que contiene dos alturas, contiene en sus casilleros distintos formatos. Es por esta razón que decidimos realizar nuestro análisis de calidad sobre esta columna.

Entendemos que al existir distintos tipos de formatos en los casilleros de "Domicilio" representa un problema en el procedimiento de recolección de datos. Es decir que este es un problema de calidad del tipo Procesos. Debido a que seguramente no se le aclaró al usuario el formato en el cual el dato domicilio está completo. Para este análisis decidimos tomar como domicilio completo a los datos dados como calle y altura. Por lo que tenemos dos atributos de calidad que se ven afectados. Existen algunos casilleros en "Domicilio" donde los datos se repiten o colocó ""Sin Dirección ","Belgrano ","15 4211",etc.. Vemos que al tener entradas como estas se genera un problema de Completitud, ya que no están presentes los datos para representar la realidad correctamente. En cuanto a los casilleros donde se repite la dirección para dos localidades distintas, notamos un problema de consistencia. Debido a que esto genera contradicciones entre los datos almacenados. Teniendo en cuenta estos dos problemas nos decidimos en dos métricas para evaluar cual es la proporción de Bibliotecas que tienen el dato "Domicilio" completo y cual es la proporción de datos inconsistentes en "Domicilio".

La primera de estas es la cantidad de datos completos (calle, altura), dividido la totalidad de los datos.

$$\frac{\text{Cantidad datos completos}}{\text{Cantidad total de datos}} = \frac{1704}{1902} \approx 0.896 \rightarrow 89.6\%$$

Vemos entonces que el dato "Domicilio" tiene en su 89.6% datos completos, osea el 10.4% son datos incompletos. En la segunda métrica vemos la relación de los domicilios repetidos y la cantidad total de estos.

$$\frac{\text{Cantidad datos repetidos}}{\text{Cantidad total de datos}} = \frac{72}{1902} \approx 0.379 \rightarrow 4\%$$

De manera que la segunda métrica indica que cerca del 4% de los datos de "Domicilio" Desglosando la información obtenida, vemos que el 14.4% de los datos de "Domicilio" son datos obsoletos. Por lo que el dato "Domicilio" tiene poca relevancia a la hora de analizar la tabla BP.

Para resolver este problema, que como nombramos previamente se trata de un error en el método de recolección de datos, consideramos que se tendrían que haber dado instrucciones más claras para los usuarios que cargan las BPs en la base de datos.

DER:

Para la realización del Diagrama Entidad Relación, lo primero que hicimos fue identificar las entidades que íbamos a relacionar. Decidimos tomar la entidad "Departamento" como la central, ya que era la que estaba relacionada con el resto. Luego, identificamos las relaciones entre cada una: los Establecimientos Educativos y las Bibliotecas Populares están "ubicados en" los Departamentos; y la Población "vive en" los Departamentos.

Unidas todas las entidades, ilustramos el tipo de relación entre cada una de ellas: para "EE" y "Departamentos" consideramos que un departamento puede tener muchas escuelas o puede no tener ninguna (parcial), mientras que una escuela tiene que estar ubicada en un departamento y, a la vez, no puede estar ubicada en más de uno (total),

entonces, la relación es “muchos-a-uno; para “BP” y “Departamentos” consideramos el mismo criterio que el anterior. Una relación “muchos-a-uno” donde la relación de bibliotecas es parcial y la de departamentos es total; y por último, para “Población” y “Departamentos” tuvimos en cuenta que una población debe vivir en al menos un departamento y en no más de uno (total), y por otro lado, un departamento debe tener una población y, a su vez, no más de una (total). Por ende, la relación es “uno-a-uno”.

Paso siguiente, a partir de las tablas, seleccionamos los atributos para cada una de las entidades. Para los “Establecimientos Educativos” elegimos “cueanexo” como clave primaria, “Nivel Inicial - Jardín Maternal”, “Nivel Inicial - Jardín de Infantes”, “Primario”, “Secundario” y “nombre_ee”. Para las “Bibliotecas Populares” elegimos “nro_conabip” como clave primaria, “mail” y “fecha_fundacion”. Para “Departamentos” elegimos “id_departamento” como clave primaria, “nombre_departamento” y “nombre_provincia”. Y para “Población” elegimos “poblacion_jardin”, “poblacion_primarias”, “poblacion_secundarias” y “poblacion_adultos”. En este caso, tomamos la entidad “Departamentos” como clave primaria.

Modelo Relacional

A partir del DER , ideamos un modelo relacional que reúna la información de las entidades de una manera efectiva para poder resolver los ejercicios de consultas SQL y Gráficos. Armamos 4 tablas: “Establecimientos”, “Bibliotecas”, “Departamentos” y “Población”. Las dos primeras son las tablas derivadas de las tablas EE y BP respectivamente. La tabla “Población” es la derivada de las tablas de población obtenidas desde el sitio del INDEC, como explicamos luego en el apartado “Decisiones Tomadas”. “Departamentos” contiene las columnas “id_departamento”, “Provincia” y “Departamento”. La columna que se repite en todas las tablas y funciona como FK es la columna “id_departamento”. A partir de este dato vamos a poder hacer los JOIN necesarios para realizar las actividades.

Ya con un modelo a seguir, comencemos descomponiendo la tabla EE en la tabla “Establecimientos” cumpliendo 3FN. Veamos que, una vez que hicimos cumplir a la tabla 1FN (descartando las columnas con valores multivaluados), la tabla esta vez no cumplía 2FN, ya que habían relaciones parciales. Por ejemplo: Localidad, Código de localidad y Departamento dependían de Código de Departamento. Ésta no era nuestra PK (nuestra PK era Cueanexo). La solución que encontramos fue descomponer en otras tablas, dejando Código de Departamento como FK entre ambas.

Veamos entonces cómo nos queda el esquema. Creamos la tabla “Establecimientos” que contiene los siguientes campos: (Cueanexo, Nombre, Código de departamento (ID), Nivel inicial- Jardin Maternal, Nivel Inicial - Jardín de Infantes, Primario, Secundario) donde Cueanexo es la clave primaria (No hay establecimiento con el mismo Cueanexo) y Código de departamento es la clave foránea para conectar esta tabla con la tabla “Departamentos”. (Veamos que por más que haya filas null, esto tan solo ocupará más espacio,pero seguirá siendo 3FN. Estas columnas siguen siendo determinantes para resolver las actividades propuestas, por lo que no las podemos descartar)

Finalmente la tabla “Departamentos” contiene: (Código de departamento (ID), Jurisdicción(Provincia en la tabla BP), Departamento).

Ambas tablas cumplen se encuentran en 3FN, ya que no tienen ninguna dependencia transitiva, ni valores multivaluados o compuestos.

Pasando a la limpieza de la tabla BP, como se puede ver en el DER, decidimos construir a partir de esta la tabla "Bibliotecas". Esta tiene como columnas a "nro_conabip", "id_departamento", "mail" y "fecha_fundación". Elegimos "nro_conabip" como PK ya que cada BP tiene un número de conabip único y "id_departamento" como FK para conectar con las demás tablas como se puede apreciar en el DER. Vemos también que los atributos restantes dependen únicamente de "nro_conabip". Por lo que al no existir dependencias transitivas, ni dependencias parciales y al ser todos los datos atómicos, podemos afirmar que Bibliotecas es 3FN.

DECISIONES TOMADAS:

Lo primero que planteamos fue un esquema ordenado de cómo íbamos a realizar el trabajo. Primero analizamos las tablas y las limpiamos en base a los datos que iban a ser útiles y los que no. Por ejemplo, en la tabla EE, decidimos descartar columnas como "Sector", ya que esa información no la necesitábamos, y dentro de "Modalidad", solo tuvimos en cuenta, de la sección "Común", los niveles iniciales, primarios y secundarios. Por otro lado, en la tabla BP descartamos columnas como "categoría", "piso", "latitud", etc, ya que su información era irrelevante para nuestra investigación además de tener una calidad decepcionante. Optamos también por agrupar todas las comunas de la Ciudad Autónoma de Buenos Aires en un solo departamento con un único ID, porque en la tabla de BP, CABA aparece como un único departamento (sin división en comunas). Veamos que las BP ubicadas en la provincia Ciudad Autónoma de Buenos Aires tenían en su atributo "Departamento" el dato Ciudad Autónoma de Buenos Aires. Entonces optamos por omitir su división administrativa en las demás tablas también. Acerca de la tabla de población por edades, tomamos la decisión de no usar la del enunciado, ya que la información tenía una distribución de columnas y filas muy incómoda para trabajar con SQL. Por eso, preferimos construir cuatro tablas desde la web INDEC¹ que además nos permitió dividir por grupos etarios de una manera más efectiva.

Luego a partir de nuestros esquemas realizamos los reportes que nos solicitaron. Trabajamos con consultas SQL. Utilizamos los esquemas en su totalidad, por lo que quedó demostrado que no conservamos ningún dato irrelevante. Una vez generadas las tablas, tan solo nos quedaba la visualización y análisis de datos. Antes de arrancar con cada gráfico, tomamos varias opciones en cuenta para realizarlos. Luego de comparar nuestras posibilidades, logramos encontrar la que, a nuestro parecer, era la mejor opción para representar los datos (para cada gráfico).

¹ <https://redata.indec.gob.ar/binarg/RpWebEngine.exe/Portal?BASE=CPV2022&lang=ESP>

Seccion de analisis de datos²³:

Consulta 1:

Provincia	Departamento	Jardines	Poblacion Jardines	Primarias	Poblacion Primaria	Secundarias	Poblacion Secundaria
Buenos Aires	LA MATANZA	333	157034	335	1837168	336	1837168
Buenos Aires	LA PLATA	234	52075	201	756074	211	756074
Buenos Aires	LOMAS DE ZAMORA	170	50825	179	685644	191	685644
Buenos Aires	GENERAL PUEYRREDON	178	41427	168	660569	173	660569
Buenos Aires	QUILMES	160	47353	145	631774	151	631774
Buenos Aires	MORENO	120	50791	138	575758	134	575758
Buenos Aires	ALMIRANTE BROWN	140	43762	137	583209	146	583209
Buenos Aires	MERLO	108	48007	120	581484	125	581484
Buenos Aires	LANUS	118	28133	117	460081	113	460081
Buenos Aires	PILAR	108	34493	112	393614	105	393614

Consulta 2:

Provincia	Departamento	Cantidad de BP fundadas desde 1950
Buenos Aires	LA MATANZA	15
Buenos Aires	LA PLATA	15
Buenos Aires	MORENO	13
Buenos Aires	BAHIA BLANCA	12
Buenos Aires	TIGRE	12
Buenos Aires	ALMIRANTE BROWN	10
Buenos Aires	GENERAL SAN MARTIN	10
Buenos Aires	LOMAS DE ZAMORA	10
Buenos Aires	TANDIL	10
Buenos Aires	AVELLANEDA	9

Consulta 3:

² Todas las tablas de consultas SQL se pueden ver en la carpeta "ConsultasSQL"

³ Todos los gráficos se pueden ver en la carpeta "Graficos"


Provincia	Departamento	Cant_EE	Cant_BP	Poblacion
Ciudad de Buenos Aires	CIUDAD AUTÓNOMA DE BUENOS AIRES	2286	43	8838708
Córdoba	CAPITAL	1151	20	4212203
Buenos Aires	LA MATANZA	1004	16	5104420
Santa Fe	ROSARIO	958	39	3765639
Buenos Aires	LA PLATA	646	33	2122898
Entre Ríos	PARANA	601	11	1091165
Buenos Aires	LOMAS DE ZAMORA	540	12	1914708
Buenos Aires	GENERAL PUEYRREDON	519	6	1861412
Santa Fe	LA CAPITAL	503	23	1593281
Salta	CAPITAL	469	27	1740710

Consulta 4:

Provincia	Departamento	Dominio más Frecuente en BP
Buenos Aires	AZUL	
Buenos Aires	GENERAL ALVEAR	yahoo
Buenos Aires	BOLIVAR	yahoo
Buenos Aires	CORONEL SUAREZ	gmail
Buenos Aires	GENERAL VILLEGAS	servicoopsa
Buenos Aires	MAGDALENA	gmail
Buenos Aires	MARCOS PAZ	gmail
Buenos Aires	SAAVEDRA	yahoo
Buenos Aires	TAPALQUE	tapalque
Buenos Aires	TIGRE	


Gráficos:

i)




Para representar la cantidad de BP por provincia optamos por un gráfico de barras. Es fácil de identificar que hay una diferencia abismal entre la cantidad de BP en la provincia de Buenos Aires con el resto de las provincias. Incluso comparándolo con CABA la diferencia es de más de quince mil. Si bien las primeras 3 provincias con más BP también son las 3 provincias con más habitantes, el resto de provincias no tienen una relación directa entre su población y la cantidad de BP. Veamos que Chaco está por encima de CABA, con menos de la mitad de habitantes. Por lo tanto no hay una relación directa entre la cantidad de BP y los habitantes de esa provincia.

ii)



Realizamos un gráfico de dispersión para representar la cantidad de establecimientos educativos de cada departamento en función de su población. Donde cada punto es un departamento y hay tres colores para diferenciar de qué nivel educativo se trata (Jardín, Primaria, Secundaria). En el gráfico se ve claramente que a medida que crece la población, crece la cantidad de EE. Es decir, hay una correlación positiva entre ambas variables. Hay que destacar también, que hay un valor muy elevado de Jardines para un número no tan elevado de población. Este podría ser considerado un valor atípico pero sin embargo una explicación que encontramos a esta situación es que los jardines suelen tener menor capacidad de alumnos, en consecuencia se necesitan una mayor cantidad de establecimientos de este nivel educativo.

iii)




En el caso del gráfico “Cantidad de EE por Departamento por Provincia”, al ser una visualización de distintos boxplots, comparamos la dispersión de los datos de cantidad de EE por departamento de cada provincia. Notamos que como consecuencia de nuestra decisión de tomar CABA como único partido de Ciudad de Buenos Aires hace que el dato de Ciudad de Buenos Aires dificulte la visualización del gráfico. Ya que tendríamos que alargar el eje x para colocar solo un punto dedicado a CABA. Por lo cual, preferimos anotar el dato de CABA en la parte inferior del gráfico, fuera de los ejes y notarlo como un valor atípico.

Ahora sí, en cuanto lo que se encuentra en los ejes, vemos que las provincias con las medianas más bajas son las que presentan boxplots más pequeños. Indicando poca variación de cantidad de EE por departamento. Cuando pasamos a provincias con medianas más altas vemos que la dimensión de sus boxplots aumenta. En el caso de Buenos Aires, aunque el boxplot es pequeño, tiene una gran cantidad de valores outliers. Mostrando una alta heterogeneidad en la distribución de EE en sus departamentos. Vemos como Entre Ríos, Misiones, Córdoba y Santa Fe tienen boxplots más grandes que Buenos Aires. Indicando que estas tienen una distribución más concentrada de EE. Sin embargo también tienen algunos de los valores atípicos más altos, mostrando la amplitud de su distribución. En los casos de Córdoba y Santa Fe asociamos estos valores atípicos a que hospedan en ellas a dos de los centros urbanos más grandes del país.

En general, la mayoría de provincias presentan una distribución más homogénea de EE. Es en los casos de provincias con grandes centros urbanos donde esta se amplía más.

iv)



En el siguiente gráfico se puede observar la relación entre BP y EE cada 1000 habitantes por departamento. En el eje horizontal se encuentran los valores de la proporción de BP y en el eje vertical la de EE. Cada puntito en el gráfico representa un departamento, los cuales están identificados con un color relacionado con la provincia a la cual pertenecen. Al ser la proporción cada 1000 habitantes por departamento, elegir un gráfico de barras, por ejemplo, se hacía muy incómodo, ya que la cantidad de departamentos es muy extensa y no entraban todos. Además, hay nombres que se repiten, así que teníamos que buscar una opción que identificara cada departamento con su provincia. Este gráfico de distribución nos pareció el más adecuado, ya que aunque no se llegan a identificar todos los departamentos, se puede observar una tendencia muy clara a una proporción de entre 0 y 0,2 bibliotecas y 0 y 2 escuelas cada 1000 habitantes. También se nota que hay muchos departamentos los cuales tienen 0 bibliotecas o una proporción muy baja (0,0001), mientras que la proporción de escuelas varía más, y ninguna llega a 0.

CONCLUSIÓN:

Al comenzar este trabajo nos preguntamos si existe una relación entre la cantidad de establecimientos educativos en cada una de las provincias y la cantidad de bibliotecas populares. A partir de las tablas realizadas en las actividades de SQL y los gráficos que derivamos de ellas, podemos concluir lo siguiente:

Por un lado, la cantidad de EE por provincia está positivamente correlacionado con su cantidad de habitantes ("Cantidad EE en función de la población"⁴). La cantidad de BP en cambio no está exclusivamente relacionada con la población de su respectiva provincia

⁴ Gráfico ii

("Cantidad de BP Provincia"⁵). Además en el gráfico "Relación entre BP y EE cada mil habitantes"⁶ podemos ver que la cantidad de EE (cada mil habitantes) no aumenta a la par de la cantidad de BP (cada mil habitantes). Es más, cuando más EE hay, es cuando el valor de BP es cero, lo cual es otro dato interesante, ya que indica que existen departamentos en los que no hay bibliotecas populares, a diferencia de los establecimientos educativos que por lo menos hay uno en cada departamento.

Concluyendo, podemos ver como no se presenta ningún patrón que pueda demostrar una relación entre la cantidad de bibliotecas y de establecimientos educativos en los departamentos del país. Ya que los valores de éstos varían de manera independiente entre ellos. Podríamos decir que, en realidad, la cantidad de establecimientos educativos está más relacionada a la distribución administrativa y urbana de cada provincia, como se puede ver en el gráfico "Cantidad de EE por Departamento por Provincia"⁷. Sin embargo, este es un dato que no se tuvo en cuenta en la investigación, las características geográficas de cada departamento.

⁵ Gráfico i

⁶ Gráfico iv

⁷ Gráfico iii