

Trabajo Práctico 2: Fashion-MNIST

Fecha: 16/06/2025


Nombre del grupo: "B.O.B"

Integrantes:

- Tomas Libson
- Pedro Raffo
- Felipe Comas

Análisis Exploratorio


Para analizar los atributos más relevantes para cada clase, decidimos realizar un heatmap para cada una de ellas. Analizando el promedio de cada atributo (el valor promedio de cada píxel) de cada clase.



Inicialmente notamos que hay clases muy similares. La clase 2, 4 y 6 (Pullover, Abrigo y Camisa) tienen una distribución casi idéntica. Esto se debe a que son prendas de torso con mangas largas. Esto mismo es lo que las diferencia de las demás clases. Vemos que, en general, aproximadamente entre los píxeles 3 - 6 y 21 - 24 horizontales y 4 - 26 verticales, los valores de estos atributos son altos. De ahí el blanco presente en la figura.

También encontramos grandes similitudes entre las clases 5, 7 y 9 (Sandalias, Zapatillas y Borcegos). Vemos que en estos casos su característica más identificativa es su recorrido horizontal y central en el heatmap. En el caso de las clases 5 y 7 consideramos como relevantes los valores de la línea horizontal a la altura del píxel 18. Para la clase 9 veremos la línea a la altura del píxel 20. Además, para diferenciar esta última de las demás nos va a interesar la diferencia de la presencia vertical en el heatmap. Es decir, identificar la "Bota" del borcego entre los píxeles 15 - 27 horizontales. También queremos agregar, que la clase 5 presenta un heatmap más bien difuminado. Esto es un indicio de la heterogeneidad dentro de la clase.

Ejemplos de la Clase 5 (Sandalias)



Ejemplos de la Clase 7 (Zapatillas)



Viendo algunos ejemplos de prendas de la clase 5 vemos que esta es en efecto muy variada. Con prendas que ocupan distintas regiones de la grilla 28x28. También agregamos ejemplos de la clase 7 para tener una comparación visual con una clase que no presenta tanta variación.

En cuanto a las demás clases notamos que cada una tiene una característica que las hace más fácil diferenciarlas de todas las demás. La clase 0 (Remera) tiene, a contraposición con la 2,4 y 6, una ausencia de “calor” en las mangas. Es decir, mangas cortas. La clase 1 (Pantalón) representa la única prenda de piernas de nuestro DataBase. Por lo que vamos a tomar como característico de esta a su angosta presencia horizontal, su larga presencia vertical y el espacio entre ambas piernas del pantalón. Esto último es lo que nos va ayudar


a diferenciar la clase 1 de la clase 3 (Vestido). Ya que esta cumple con las primeras dos características mencionadas para la clase 1 pero no presenta el espacio mencionado en la última característica. Por último, tenemos la clase 8 (Cartera) que, como se puede apreciar en el heatmap, ocupa una gran porción de este. Por lo que tomaremos como característica principal es la cantidad de espacio que ocupa en el recuadro 28x28.

Clasificación Binaria

Para responder la la pregunta “¿La imagen incógnita pertenece a la clase 0 o a la clase 8?” comenzamos por filtrar la base de datos original, quedándonos solamente con las prendas pertenecientes a estas clases. Luego, nos aseguramos que la cantidad de muestras de las clases esté balanceada para poder realizar un modelado efectivo. Vemos que en nuestro dataset filtrado existen 7000 muestras para cada clase. Por lo tanto decimos que está balanceado.

A partir de nuestro dataset filtrado, procedimos a construir distintos subconjuntos “Train” para comparar resultados. Para los primeros 3 subconjuntos (a,b y c), decidimos enfocarnos en la característica “manga corta” de la clase 0.

Heatmap Clases 0 y 8



Como se puede apreciar en “Heatmap Clases 0 y 8”, desde la fila 12 hasta la 28, entre las columnas 0-6 y 21-28, la Clase 0 no tiene atributos relevantes o más bien no tiene presencia en ese segmento de la grilla. Distinto es el caso de la Clase 8 que sí presenta atributos en esas áreas. Por lo tanto, decidimos que el subconjunto a se enfoque en los atributos de la “manga corta izquierda” (columnas 0-6) abarcando 112 atributos y el b la “manga corta derecha” (columnas 21-28) con 1123 atributos. Decidimos que el c ocupe

menos filas pero que analice ambas mangas cortas (filas 14-20 y columnas 3-6 y 21-24), abarcando 56 atributos.

En cuanto a la otra mitad de subconjuntos decidimos enfocarnos en los atributos posicionados en la parte superior de la grilla, osea los “hombros” (filas 0- 6) de la Clase 0 y la “correa” de la Clase 8 . Ya que notamos la poca presencia de la Clase 8 en esta área. El conjunto d se enfoca en el “hombro izquierdo” (columnas 0-9) y el e en el derecho (columnas 18-28) con 70 atributos cada uno. Por último, el conjunto f abarca el área de 21 atributos donde en la clase 8 se describe una correa (columnas 14-16), característica del bolso.

Además de variar en la elección de nuestros conjuntos train decidimos modelar para distintos valores de k (1,3,5,7 y 9). Por lo que para cada valor de k se modelo con todos los subconjuntos ya mencionados. Para cada modelo recolectamos los datos de Exactitud y Precisión, que fueron almacenados en las siguientes tablas.

Tabla Exactitud:

Exactitud	k=1	k=3	k=5	k=7	k=9	prom_sub
sub_a	93.75%	93.75%	94.00%	93.93%	93.89%	93.86%
sub_b	93.75%	94.46%	94.68%	94.46%	94.29%	94.33%
sub_c	92.29%	93.50%	94.04%	93.93%	94.00%	93.55%
sub_d	94.57%	95.29%	95.18%	94.96%	95.07%	95.01%
sub_e	96.75%	96.68%	96.43%	96.29%	96.25%	96.48%
sub_f	93.82%	94.64%	94.79%	94.82%	94.75%	94.56%
prom_k	94.15%	94.72%	94.85%	94.73%	94.71%	-

Tabla Precisión:

Precisión	k=1	k=3	k=5	k=7	k=9	prom_sub
sub_a	96.01%	95.94%	96.03%	95.81%	95.74%	95.91%
sub_b	94.91%	95.86%	96.16%	95.93%	96.05%	95.78%
sub_c	93.86%	95.29%	95.82%	95.61%	95.68%	95.25%
sub_d	95.33%	95.80%	95.25%	95.03%	95.24%	95.33%
sub_e	96.65%	96.99%	96.63%	96.62%	96.42%	96.66%
sub_f	92.50%	93.10%	93.55%	93.74%	93.85%	93.35%
prom_k	94.88%	95.50%	95.57%	95.46%	95.50%	-

Como se puede apreciar en las tablas, el subconjunto e , referido a el “hombro derecho”, es el más efectivo para entrenar al modelo. Ya que los modelos asociados a este presentan el mayor promedio de Precisión y Exactitud, además de tener el modelo más valorado en ambas métricas. Notamos también, que para este conjunto es preferible tener un valor más bien bajo de k. Ya que es en k=1 que alcanza su mayor exactitud y k=3 su mayor precisión. Aclaramos que para este conjunto en específico, porque el k que presenta el promedio más

bajo es $k=1$. Notamos que en general, es preferible realizar los modelos con valores medios de k . Decimos esto porque dentro de los k posibles es 5 el que presenta mejor promedio en ambas métricas. En cuanto al peor subconjunto, el f , vemos que aparentemente la poca cantidad de atributos perjudicó su efectividad, teniendo el menor de los promedios. En conclusión, podríamos decir que los valores medios de atributos y k son preferibles para realizar modelos kNN.

Clasificación Multiclase

El objetivo de este ejercicio era construir un modelo de árbol de decisión para clasificar imágenes del conjunto "Fashion-MNIST" en una de las 10 clases.

Primero dividimos el dataset original en dos subconjuntos. Uno que vamos a usar como conjunto de desarrollo, que representa el 90% de los datos. Donde vamos a aplicar validación cruzada para ajustar el modelo. El segundo lo llamamos conjunto "held out", que representa el 10% de los datos. Este subconjunto lo vamos a guardar para la evaluación final del modelo.

Una vez separados en los dos subconjuntos, ajustamos los modelos de árbol de decisión probando diferentes valores de profundidad máxima (max depth), variando del 1 al 10. También variamos las medidas de impureza. Probamos con Gini, Entropy y Log-loss. La medida que mejores resultados obtuvo fue Entropy, así que es la que utilizamos para seguir. Cada configuración fue evaluada usando validación cruzada para estimar su rendimiento. Llegamos a que el mayor promedio de exactitud (accuracy) lo alcanzamos con la altura máxima = 10. Con este valor alcanzamos un Accuracy promedio = 0.8066.

Entonces finalmente, utilizamos el modelo con max depth = 10, y entrenamos nuevamente todo el subconjunto de desarrollo. Alcanzamos una performance final y obtuvimos los siguientes valores. La exactitud en el subconjunto dev = 0.8509 y la exactitud en el subconjunto held-out = 0.8149. Logramos entonces construir un clasificador multiclase con un árbol de decisión, y la exactitud que alcanzamos es de 81,49 %.


Estos resultados son más que aceptables, sin embargo nos dimos cuenta que el código tarda aproximadamente 7 minutos en correr. Una posible solución que encontramos es: Reducir el dataset que utilizamos para la validación cruzada. Tomamos el 30% del conjunto de desarrollo para acelerar la cross-validation. Veamos que esto no va a afectar al modelo final que se va a entrenar con todos los datos, simplemente acelera la experimentación. Si bien los resultados del accuracy promedio por altura son más bajos, la mejor altura sigue siendo 10. Finalmente la exactitud en el conjunto held-out es levemente más baja que antes, pero aceptamos esta mínima pérdida con tal de ganar velocidad (Reducimos 5 minutos). La performance final que obtuvimos es: exactitud en el subconjunto dev = 0.8509 y exactitud en el subconjunto held-out = 0.8130.

Ahora para visualizar más fácilmente los resultados obtenidos, hicimos dos gráficos. Primero hicimos un gráfico donde podemos ver como varía la exactitud promedio según el hiperparámetro max depth elegido para hacer la validación cruzada. Luego, hicimos la



matriz de confusión del modelo final, para ver cómo se comportó el modelo al clasificar los ejemplos reales del subconjunto Held-out.

Tomamos la decisión de mostrar tanto los resultados originales (sin reducir el dataset del cross-validation), para demostrar la mínima pérdida generada por esta estrategia. Si bien no están incluidos en el código final, nos pareció importante incluirlos en el informe.

A continuación se muestran los resultados originales:



Ahora veamos los resultados obtenidos al acelerar la validación cruzada:



Podemos ver que justamente sucedió lo que nombramos en la sección “Análisis exploratorio”. Las clases visualmente más parecidas, por ejemplo la 2, 4 y 6 son las que tienen los valores más bajos en la diagonal. Esto era esperable ya que tienen una distribución casi idéntica.